Além do Conjunto Limpo: Resíduos de Ruído, Treinamento Robusto e Generalização entre Bases na Detecção de Faces Manipuladas

Lucas Cunha*, Lucas Gasperin*, Lucas Sotomaior*,
Beatriz Caldas*, Eduardo Pianovski* e Júlio Nievola*

*Pontifícia Universidade Católica do Paraná, Curitiba, Brasil

*{c.oliveira25,lucas.gasperin,lucas.sotomaior,beatriz.caldas,eduardo.pianovski}@pucpr.edu.br

***Resumo*—resumo resumo resumo

C. Resíduos de ruído e pistas de baixo nível

Os SRM [10], propostos para esteganálise, são filtros passa-alta fixos que suprimem o conteúdo semântico e evidenciam o ruído local; o próprio MFFI inclui um detector baseado neles [9]. No estudo anterior, foram investigadas pistas espectrais via transformada rápida de Fourier (FFT) [15]–[17]; aqui, testa-se se resíduos espaciais são um complemento mais estável.

D. Ensembles

Os ensembles são comuns em competições como o DFDC [18], mas costumam ser relatados como um bloco único; este trabalho estuda quais combinações contribuem para o ganho, dentro e fora do domínio de treino.

III. Configuração Experimental

Descreve-se a seguir o que mudou em relação ao estudo anterior [8]; partições, limiar e métricas do MFFI seguem aquele protocolo.

A. Bases de dados

Todos os modelos são treinados apenas no MFFI, e o limiar de decisão, escolhido na sua validação, é mantido fixo em todas as bases; DF-40 e Celeb-DF v2 são usados só na avaliação, sem retreino (Tabela I).

As três bases usadas são:

- MFFI [9]: reúne mais de 50 técnicas de manipulação, aplicadas a pessoas de diferentes origens e a imagens de qualidade variada. São usadas as partições oficiais, e a versão degradada do teste é chamada de *Test-Hard* (Test-D em [9]).
- DF-40 [11]: o split oficial contém apenas imagens falsas, o que impede calcular a ROC-AUC sobre ele; por isso, são usados dois protocolos. O *protocolo 1*, não oficial, acrescenta imagens reais a uma amostra das falsas e permite calcular a ROC-AUC, comparável à das demais bases: até 250 falsas por técnica (200 para StarGAN e StarGAN v2) e 500 quadros derivados do Celeb-DF, somando 6.147 falsas, e 5.000 reais de seis fontes (WhichFaceIsReal, CollabDiff, MidJourney, StarGAN v2, StyleCLIP e HeyGen), com semente 42. O *protocolo 2*, oficial, usa todas as 650.549 falsas das 24 técnicas (troca facial, GAN, difusão, edição/*text-to-image* e o avatar comercial HeyGen); sem imagens reais, reporta-se a revocação no limiar do MFFI. Como o protocolo 1 não é oficial, seus resultados não devem ser diretamente comparados aos da literatura, sendo utilizados apenas para comparações internas deste experimento.
- Celeb-DF v2 [12]: reúne vídeos de celebridades com trocas de face com poucos artefatos visíveis. São usados os 518 vídeos da lista oficial de teste (178 reais e 340 falsos), com 15 quadros uniformemente espaçados por vídeo e a maior face recortada pelo detector Haar do OpenCV; a probabilidade atribuída ao vídeo corresponde à média das probabilidades de seus quadros, e a métrica principal é a ROC-AUC por vídeo.

Tabela I
Divisão dos dados. Só o MFFI é usado no treino.

Base	Partição	Uso	Amostras
MFFI	Treino	Treino	524.429 img.
	Validação	Limiar	147.363 img.
	Test / Test-Hard	Avaliação	181.947 img.
DF-40	Protocolo 1 (não oficial, balanceado)	ROC-AUC	5.000 reais 6.147 falsas
	Protocolo 2 (oficial, todas as técnicas)	Revocação	650.549 falsas
Celeb-DF v2	Teste oficial (15 quadros/vídeo)	ROC-AUC por vídeo	178 vídeos reais 340 vídeos falsos



Figura 1. Exemplos de faces reais e falsas de cada base.

B. Modelos e regimes de treino

Todas as famílias partem de pesos pré-treinados e sofreram *finetuning*: Xception, ResNet-18, MobileNetV3-Large e Vision Transformer (ViT)-B/16 (ImageNet), CLIP ViT-B/16 [19] e DINOv3 ConvNeXt-B [20], [21]. Os dois últimos estágios do backbone são descongelados, com taxas de aprendizado distintas para cabeça e backbone (no DINOv3, 2×10^{-4} e 2×10^{-5}), e são usados AdamW, amostragem balanceada, parada antecipada, entrada de 224×224 e 5 sementes (42, 123, 2024, 7 e 2025). No *finetuning convencional*, são usados os aumentos leves do estudo anterior (recorte, espelhamento e cor); no *robusto*, cada imagem de treino recebe ainda degradações sorteadas independentemente (Tabela II), que aproximam as do Test-Hard.

Tabela II
Degradações do treino robusto e suas probabilidades.

Degradação	Prob.	Faixa
Rotação	0,5	$\pm 30°$
Contraste	0,5	fator 0,4–1,8
Brilho	0,5	fator 0,5–1,8
Nitidez	0,3	fator 0,2–2,0
Desfoque gaussiano	0,3	raio 0,5–2,0
Compressão JPEG	0,5	qualidade 25–90
Ruído gaussiano aditivo	0,5	σ 0,01–0,08

C. Resíduos de ruído SRM

Sobre a luminância Y, aplicam-se três filtros SRM [10] fixos de 5×5: derivada horizontal de primeira ordem, Laplaciano de segunda ordem e o filtro KV de terceira ordem (Figura 2); cada resíduo é truncado em ±3 e dividido por 3. São avaliadas as variantes *RGB+SRM* (seis canais) e *SRM-only* (três), ambas no regime robusto; com mais de três canais, os pesos da primeira camada são replicados e reescalados por $3/C_{\text{in}}$.



Figura 2. Resíduos SRM de uma face real (acima) e de uma falsa (abaixo) do Celeb-DF v2.

D. Ensembles

As probabilidades de modelos já treinados são combinadas (fusão tardia) com oito estratégias: médias aritmética, geométrica e harmônica, máximo, voto majoritário, média ponderada pela ROC-AUC de validação, pesos ótimos (mínima entropia cruzada na validação) e *stacking* (regressão logística na validação). São reportados comitês Top-2 a Top-5, com membros e fusão escolhidos pela ROC-AUC na validação do MFFI, em três grupos: *espaciais*, só com RGB robusto; *híbridos*, com RGB robusto e RGB+magnitude de Fourier; e *sem RGB puro*, só com RGB+SRM e RGB+Fourier, pois nos híbridos o RGB puro domina a validação. Nos dois últimos grupos, cada membro é um checkpoint (avaliação única).

E. Métricas

A métrica principal é a ROC-AUC, independente de limiar; os valores apresentados com $\pm$ representam a média e o desvio-padrão dos resultados obtidos entre as sementes. A métrica de revocação é utilizada apenas no protocolo 2 do DF-40.

IV. Resultados e Discussão

Tabela III
ROC-AUC no MFFI (média $\pm$ desvio-padrão). Anterior: melhor cenário RGB de [8]. Δ = Test$-$Test-Hard (menor é melhor).

	Anterior [8]			Ajuste fino RGB			RGB robusto		
Família	Test	Test-Hard	Δ	Test	Test-Hard	Δ	Test	Test-Hard	Δ
Xception	**0,884**	0,609	0,275	0,773 $\pm$0,004	0,630 $\pm$0,001	0,143	0,755 $\pm$0,001	0,685 $\pm$0,004	0,070
ResNet-18	0,846	0,635	0,211	0,885 $\pm$0,011	0,665 $\pm$0,009	0,220	0,849 $\pm$0,008	0,769 $\pm$0,007	0,080
MobileNetV3	0,839	0,594	0,245	0,847 $\pm$0,002	0,670 $\pm$0,005	0,177	0,831 $\pm$0,007	0,749 $\pm$0,006	0,082
ViT	0,624	0,608	**0,016**	0,814 $\pm$0,009	0,693 $\pm$0,008	**0,121**	0,823 $\pm$0,005	0,764 $\pm$0,005	**0,059**
CLIP	0,750	0,619	0,131	0,920 $\pm$0,004	**0,749** $\pm$0,010	0,171	0,908 $\pm$0,002	**0,845** $\pm$0,002	0,063
DINOv3	0,809	**0,726**	0,083	**0,936** $\pm$0,006	0,715 $\pm$0,012	0,221	**0,927** $\pm$0,010	0,844 $\pm$0,020	0,083

A. Finetuning e treinamento robusto no MFFI

A Tabela III compara, no MFFI, o melhor cenário RGB do estudo anterior [8] com o *finetuning* convencional e o robusto deste trabalho. O *finetuning* eleva a ROC-AUC limpa de cinco das seis famílias: o DINOv3 passa de $0{,}809$ (congelado) para $0{,}936$, o CLIP de $0{,}750$ para $0{,}920$ e o ViT de $0{,}624$ para $0{,}814$. A exceção é o Xception, que cai de $0{,}884$ para $0{,}773$, o que sugere que parte de sua vantagem anterior vinha da combinação específica de arquitetura e treino do zero.

No Test-Hard, o ganho do *finetuning* convencional é pequeno: o melhor valor é o do CLIP ($0{,}749$), e o DINOv3 ajustado ($0{,}715$) fica abaixo do congelado ($0{,}726$), com Δ entre $0{,}121$ e $0{,}221$. Uma explicação plausível é que o ajuste especializa o backbone em pistas frágeis do conjunto limpo. O treinamento robusto corrige esse efeito: a ROC-AUC no Test-Hard aumenta em todas as famílias, de $+0{,}055$ (Xception) a $+0{,}130$ (DINOv3), o Δ cai para $0{,}059$–$0{,}083$, e o custo no Test fica entre $-0{,}036$ e $+0{,}008$. CLIP ($0{,}845$) e DINOv3 ($0{,}844$) robustos superam em cerca de $0{,}12$ o melhor resultado degradado do estudo anterior.

B. Representações de entrada: Fourier e SRM

A Tabela IV reúne as sete representações do estudo anterior, com *finetuning* convencional, e as três variantes robustas, no MFFI, no DF-40 e no Celeb-DF v2. As representações puramente espectrais ficam perto do acaso fora do conjunto limpo: entre $0{,}496$ e $0{,}554$ no Test-Hard e, salvo o MobileNetV3 com *Complex Spectrum* ($0{,}598$), entre $0{,}418$ e $0{,}526$ no DF-40. Combinada ao RGB, a magnitude de Fourier tem efeito misto: no DF-40, sobe no ResNet-18 ($0{,}691 \rightarrow 0{,}780$) e no DINOv3 ($0{,}721 \rightarrow 0{,}756$), mas cai no MobileNetV3 e no ViT; no Celeb-DF v2, cai em todas as famílias, e a variante *RGB+Freq* tem os piores valores nessa base ($0{,}366$–$0{,}458$).

Os resíduos SRM se comportam de forma mais estável. Concatenados ao RGB no regime robusto, mudam pouco o Test-Hard ($+0{,}007$ no DINOv3 e perdas de até $0{,}013$ nas demais famílias), mas melhoram o DF-40 em cinco das seis famílias, com os maiores ganhos no DINOv3 ($+0{,}033$), no MobileNetV3 ($+0{,}030$) e no ViT ($+0{,}022$). No Celeb-DF v2, o DINOv3 passa de $0{,}656$ para $0{,}755$ de ROC-AUC por vídeo. Esse padrão é consistente com os resíduos funcionando como complemento da aparência, e não como substituto.

Sem o RGB, o desempenho no MFFI cai em todas as famílias. As redes neurais convolucionais (CNNs) SRM-only mantêm resultados razoáveis (ResNet-18 com $0{,}818$ no Test e $0{,}723$ no Test-Hard), enquanto os transformers colapsam no DF-40 ($0{,}408$ no ViT e $0{,}333$ no CLIP), possivelmente porque, pré-treinados em imagens naturais, dependem da aparência e não se adaptam a entradas só de ruído com poucas épocas. No Celeb-DF v2, porém, as CNNs SRM-only chegam a $0{,}731$–$0{,}745$, acima de suas versões RGB+SRM, e o DINOv3 SRM-only tem o melhor valor individual da base ($0{,}763$). Esse último resultado é parcial, pois o SRM-only ainda não tem todas as sementes.

Tabela IV

ROC-AUC (MÉDIA ± DESVIO-PADRÃO) POR FAMÍLIA E REPRESENTAÇÃO; C/DA: TREINO ROBUSTO. DF-40 P1: ROC-AUC NO PROTOCOLO 1; P2: REVOCAÇÃO (%) NO PROTOCOLO 2, SEMENTE 42; –: NÃO AVALIADO. Δ = TEST−TEST-HARD, EM NEGRITO SÓ PARA TEST $\geq 0{,}6$.

		MFFI			Entre bases (sem retreino)		
Família	Representação	Test	Test-Hard	Δ	DF-40 P1 (ROC-AUC)	DF-40 P2 (rev., %)	Celeb-DF v2 (vídeo)
Xception [22]	*RGB*	0,771 ±0,006	0,639 ±0,022	0,132 ±0,027	0,730 ±0,024	–	0,656 ±0,024
	Log-Magnitude	0,704 ±0,008	0,533 ±0,008	0,171 ±0,004	0,418 ±0,027	–	0,533 ±0,016
	Phase	0,589 ±0,006	0,511 ±0,005	0,078 ±0,003	0,481 ±0,025	–	0,561 ±0,007
	Complex Spectrum	0,562 ±0,004	0,517 ±0,004	0,045 ±0,005	0,489 ±0,014	–	0,563 ±0,015
	RGB+Mag	0,733 ±0,004	0,612 ±0,003	0,121 ±0,003	0,734 ±0,011	–	0,584 ±0,019
	High-Pass Spectrum	0,699 ±0,013	0,533 ±0,011	0,166 ±0,004	0,456 ±0,032	–	0,552 ±0,013
	RGB+Freq	0,659 ±0,006	0,575 ±0,005	0,085 ±0,004	0,597 ±0,016	–	0,458 ±0,021
	RGB c/DA	0,756 ±0,003	0,685 ±0,004	0,071 ±0,005	0,673 ±0,010	–	0,590 ±0,030
	RGB+SRM c/DA	0,753 ±0,005	0,682 ±0,005	0,071 ±0,002	0,686 ±0,014	92,3	0,582 ±0,027
	SRM-only c/DA	0,720 ±0,007	0,636 ±0,002	0,085 ±0,005	0,645 ±0,015	91,2	0,745 ±0,019
ResNet-18 [23]	*RGB*	0,876 ±0,022	0,680 ±0,039	0,196 ±0,058	0,691 ±0,032	–	0,724 ±0,038
	Log-Magnitude	0,750 ±0,009	0,541 ±0,013	0,209 ±0,005	0,451 ±0,049	–	0,531 ±0,025
	Phase	0,647 ±0,007	0,521 ±0,002	0,126 ±0,006	0,505 ±0,012	–	0,637 ±0,013
	Complex Spectrum	0,699 ±0,035	0,544 ±0,009	0,156 ±0,026	0,476 ±0,048	–	0,589 ±0,059
	RGB+Mag	0,872 ±0,011	0,666 ±0,023	0,206 ±0,017	0,780 ±0,016	73,7	0,649 ±0,027
	High-Pass Spectrum	0,750 ±0,006	0,536 ±0,005	0,213 ±0,006	0,442 ±0,010	–	0,529 ±0,021
	RGB+Freq	0,834 ±0,007	0,687 ±0,010	0,147 ±0,005	0,707 ±0,032	85,5	0,386 ±0,019
	RGB c/DA	0,847 ±0,009	0,767 ±0,008	0,079 ±0,002	0,674 ±0,026	74,0	0,651 ±0,033
	RGB+SRM c/DA	0,837 ±0,009	0,754 ±0,011	0,083 ±0,002	0,680 ±0,036	74,8	0,657 ±0,038
	SRM-only c/DA	0,818 ±0,004	0,723 ±0,001	0,095 ±0,004	0,647 ±0,010	84,6	0,735 ±0,007
MobileNetV3 [24]	*RGB*	0,845 ±0,005	0,683 ±0,033	0,162 ±0,037	0,704 ±0,014	–	0,673 ±0,019
	Log-Magnitude	0,718 ±0,006	0,542 ±0,003	0,176 ±0,005	0,451 ±0,018	–	0,551 ±0,013
	Phase	0,629 ±0,005	0,523 ±0,003	0,105 ±0,002	0,510 ±0,019	–	0,551 ±0,014
	Complex Spectrum	0,687 ±0,004	0,534 ±0,003	0,153 ±0,002	0,598 ±0,045	–	0,561 ±0,013
	RGB+Mag	0,805 ±0,007	0,630 ±0,003	0,175 ±0,007	0,668 ±0,018	–	0,569 ±0,019
	High-Pass Spectrum	0,713 ±0,007	0,545 ±0,009	0,168 ±0,003	0,426 ±0,030	–	0,577 ±0,020
	RGB+Freq	0,708 ±0,002	0,603 ±0,003	0,105 ±0,002	0,564 ±0,025	–	0,415 ±0,022
	RGB c/DA	0,832 ±0,006	0,749 ±0,006	0,083 ±0,004	0,706 ±0,019	80,8	0,686 ±0,014
	RGB+SRM c/DA	0,828 ±0,005	0,740 ±0,007	0,088 ±0,005	0,736 ±0,010	82,2	0,707 ±0,025
	SRM-only c/DA	0,777 ±0,013	0,666 ±0,007	0,111 ±0,007	0,665 ±0,032	–	0,731 ±0,041
ViT [25]	*RGB*	0,815 ±0,009	0,704 ±0,028	0,111 ±0,027	0,704 ±0,016	–	0,694 ±0,042
	Log-Magnitude	0,724 ±0,009	0,535 ±0,009	0,189 ±0,009	0,445 ±0,020	–	0,553 ±0,027
	Phase	0,602 ±0,005	0,496 ±0,003	0,106 ±0,002	0,526 ±0,018	–	0,539 ±0,012
	Complex Spectrum	0,570 ±0,009	0,554 ±0,006	0,016 ±0,006	0,509 ±0,011	–	0,501 ±0,019
	RGB+Mag	0,826 ±0,003	0,712 ±0,006	0,114 ±0,004	0,632 ±0,024	–	0,588 ±0,023
	High-Pass Spectrum	0,724 ±0,007	0,528 ±0,007	0,196 ±0,002	0,472 ±0,030	–	0,557 ±0,020
	RGB+Freq	0,791 ±0,007	0,676 ±0,006	0,116 ±0,007	0,542 ±0,022	–	0,452 ±0,014
	RGB c/DA	0,822 ±0,005	0,763 ±0,005	0,059 ±0,001	0,724 ±0,018	–	0,671 ±0,019
	RGB+SRM c/DA	0,818 ±0,006	0,765 ±0,006	0,054 ±0,005	0,746 ±0,009	83,5	0,628 ±0,019
	SRM-only c/DA	0,659 ±0,001	0,610 ±0,007	**0,048** ±0,007	0,408 ±0,067	–	0,496 ±0,013
DINOv3 [20]	*RGB*	**0,934** ±0,007	0,737 ±0,055	0,197 ±0,060	0,721 ±0,029	–	0,724 ±0,077
	Log-Magnitude	0,761 ±0,003	0,536 ±0,004	0,225 ±0,004	0,484 ±0,026	–	0,517 ±0,023
	Phase	0,713 ±0,007	0,533 ±0,009	0,180 ±0,007	0,521 ±0,026	–	0,625 ±0,018
	Complex Spectrum	0,499 ±0,001	0,498 ±0,005	0,002 ±0,004	0,500 ±0,000	–	0,504 ±0,024
	RGB+Mag	0,917 ±0,007	0,683 ±0,010	0,233 ±0,009	0,756 ±0,021	80,7	0,696 ±0,021
	High-Pass Spectrum	0,763 ±0,017	0,537 ±0,006	0,226 ±0,014	0,500 ±0,027	–	0,547 ±0,029
	RGB+Freq	0,860 ±0,008	0,682 ±0,010	0,178 ±0,004	0,705 ±0,039	**93,4**	0,366 ±0,019
	RGB c/DA	0,927 ±0,009	0,845 ±0,018	0,081 ±0,011	0,775 ±0,034	83,3	0,656 ±0,022
	RGB+SRM c/DA	0,923 ±0,008	**0,852** ±0,007	0,071 ±0,011	0,808 ±0,025	86,7	0,755 ±0,045
	SRM-only c/DA	0,792 ±0,013	0,708 ±0,012	0,084 ±0,001	0,614 ±0,024	91,5	**0,763** ±0,029
CLIP [19]	*RGB*	0,917 ±0,006	0,765 ±0,041	0,152 ±0,046	0,764 ±0,046	–	0,713 ±0,028
	Log-Magnitude	0,734 ±0,001	0,530 ±0,004	0,204 ±0,004	0,483 ±0,024	–	0,516 ±0,014
	Phase	0,627 ±0,010	0,499 ±0,002	0,127 ±0,009	0,518 ±0,033	–	0,559 ±0,029
	Complex Spectrum	0,527 ±0,038	0,520 ±0,025	0,007 ±0,013	0,472 ±0,055	–	0,470 ±0,060
	RGB+Mag	0,894 ±0,004	0,726 ±0,012	0,168 ±0,015	0,765 ±0,032	–	0,639 ±0,030
	High-Pass Spectrum	0,732 ±0,006	0,533 ±0,007	0,199 ±0,010	0,473 ±0,027	–	0,573 ±0,011
	RGB+Freq	0,779 ±0,007	0,650 ±0,006	0,128 ±0,011	0,594 ±0,021	–	0,430 ±0,028
	RGB c/DA	0,907 ±0,001	0,845 ±0,002	0,062 ±0,002	**0,814** ±0,013	35,0	0,670 ±0,014
	RGB+SRM c/DA	0,896 ±0,004	0,835 ±0,003	0,061 ±0,005	0,810 ±0,018	77,1	0,653 ±0,037
	SRM-only c/DA	0,655 ±0,012	0,603 ±0,012	0,052 ±0,003	0,333 ±0,017	–	0,552 ±0,011

C. Ensembles

A Tabela V compara comitês Top-2 a Top-5 em três grupos. Entre os espaciais, o Top-2 CLIP+DINOv3 com média geométrica é o melhor no MFFI e no DF-40, com $0{,}940$ no Test, $0{,}878$ no Test-Hard, o maior valor da tabela, e $0{,}825$ no DF-40, e cada família acrescentada reduz o Test-Hard, até $0{,}860$ no Top-5. CLIP e DINOv3 são os dois modelos individuais mais fortes e partem de pré-treinamentos distintos (imagem-texto e autossupervisão), o que favorece erros complementares; modelos mais fracos acrescentam mais ruído do que diversidade.

Os ensembles híbridos, que incluem modelos RGB+Fourier, têm a maior ROC-AUC no Test ($0{,}946$, Top-5) e no DF-40 ($0{,}865$, Top-3), mas ficam entre $0{,}787$ e $0{,}839$ no Test-Hard, abaixo de todos os comitês espaciais e do melhor modelo individual ($0{,}852$). A informação de Fourier traz,

Tabela V
ENSEMBLES TOP-2 A TOP-5 (ROC-AUC), COM MEMBROS E FUSÃO ESCOLHIDOS NA VALIDAÇÃO DO MFFI. ESPACIAIS: MÉDIA ± DESVIO-PADRÃO DE CINCO SEMENTES; DEMAIS: AVALIAÇÃO ÚNICA. DF-40: PROTOCOLO 1; CELEB-DF V2: POR VÍDEO.

Comitê	Membros	Fusão	Val	Test	Test-Hard	DF-40	Celeb-DF (vídeo)
Melhor modelo individual							
–	DINOv3 (RGB+SRM)	–	–	0,923 ±0,008	0,852 ±0,007	0,808 ±0,025	0,755 ±0,045
Ensembles espaciais (RGB robusto, 5 sementes)							
Top-2	CLIP + DINOv3	geométrica	0,996	0,940 ±0,006	**0,878** ±0,011	0,825 ±0,018	0,718
Top-3	CLIP + DINOv3 + ResNet-18	geométrica	0,996	0,935 ±0,005	0,870 ±0,010	0,801 ±0,014	0,715
Top-4	CLIP + DINOv3 + ResNet-18 + ViT	geométrica	0,995	0,929 ±0,005	0,865 ±0,009	0,797 ±0,012	0,719
Top-5	CLIP + DINOv3 + ResNet-18 + ViT + MobileNetV3	*stacking*	0,996	0,932 ±0,003	0,860 ±0,007	0,806 ±0,015	0,721
Ensembles híbridos, com RGB puro (RGB robusto + RGB+Fourier, avaliação única)							
Top-2	CLIP rob. + ResNet-18 Fourier	*stacking*	0,991	0,927	0,814	0,860	0,699
Top-3	CLIP rob. + CLIP Fourier + ResNet-18 Fourier	*stacking*	0,992	0,932	0,808	**0,865**	0,707
Top-4	CLIP rob. + CLIP Fourier + ResNet-18 Fourier + DINOv3 Fourier	*stacking*	0,996	0,942	0,787	0,857	0,748
Top-5	CLIP rob. + DINOv3 rob. + ResNet-18 Fourier + DINOv3 Fourier + Xception Fourier	pesos ótimos	**0,998**	**0,946**	0,839	0,821	0,729
Ensembles sem RGB puro (RGB+SRM e RGB+Fourier, avaliação única)							
Top-2	DINOv3 SRM + CLIP SRM	pesos ótimos	0,997	0,933	0,865	0,833	0,762
Top-3	DINOv3 SRM + CLIP SRM + ResNet-18 Fourier	pesos ótimos	0,997	0,938	0,850	0,839	**0,764**
Top-4	DINOv3 SRM + CLIP SRM + ResNet-18 Fourier + MobileNetV3 SRM	pesos ótimos	0,997	0,938	0,850	0,839	**0,764**
Top-5	DINOv3 SRM + CLIP SRM + ResNet-18 Fourier + MobileNetV3 SRM + ViT SRM	pesos ótimos	0,997	0,938	0,850	0,839	**0,764**

portanto, uma diversidade útil contra novos geradores, mas frágil sob degradação, como na Seção IV-B, e esses modelos não passaram pelo treino robusto.

Sem o RGB puro, que domina a seleção na validação, o Top-2 com DINOv3 e CLIP SRM chega a 0,865 no Test-Hard, o segundo maior valor da tabela, e os comitês desse grupo têm a maior ROC-AUC no Celeb-DF v2 (0,762–0,764), no nível do melhor modelo individual. Do Top-3 ao Top-5, os resultados não mudam, pois os pesos ótimos praticamente zeram os membros acrescentados. Como a validação do MFFI está saturada (0,991–0,998) e mal separa os comitês, a escolha depende do alvo: o Top-2 espacial para robustez, os híbridos para novos geradores e os comitês sem RGB puro para o Celeb-DF.

D. Generalização para o DF-40

No protocolo 1, a ROC-AUC dos detectores RGB+SRM treinados no MFFI varia muito entre técnicas (Tabela VI). Na fusão CLIP+DINOv3, vai de 0,988 (SD 2.1) a 0,588 (DDIM) entre os modelos de difusão e de 0,941 (StyleGAN3) a 0,574 (StarGAN v2) entre as GANs, e o HeyGen (0,566) também fica perto do acaso, enquanto as técnicas de troca facial e de edição ficam todas acima de 0,84. Os dois backbones se complementam: o CLIP é melhor em DDIM, CollabDiff, StarGAN v2, VQGAN e HeyGen, e o DINOv3, na maioria das técnicas de troca facial.

No protocolo 2, oficial, com as 650.549 falsas e o limiar da validação do MFFI, a revocação dos 17 checkpoints avaliados vai de 93,4% (DINOv3 com RGB+Fourier) a 35,0% (CLIP RGB robusto), embora o CLIP robusto tenha a maior ROC-AUC individual no protocolo 1 (0,814). Os modelos SRM-only, fracos no MFFI, estão entre os que mais detectam (DINOv3 com 91,5% e Xception com 91,2%), e no StarGAN v2 nenhum checkpoint passa de 48,6%. A contradição do CLIP robusto indica que o limiar calibrado no MFFI não transfere para outra base: a ordenação dos escores se mantém, mas a escala muda. Nos dois protocolos, os pontos cegos coincidem (avatares comerciais, parte dos geradores de difusão e StarGAN v2), o que sugere técnicas ausentes ou sub-representadas no MFFI.

Tabela VI
ROC-AUC POR TÉCNICA NO PROTOCOLO 1 DO DF-40 (MODELOS RGB+SRM). EM ITÁLICO, TÉCNICAS ABAIXO DE 0,65 NA FUSÃO.

Paradigma	Técnica	N	CLIP	DINOv3	CLIP+ DINOv3
Difusão	SD 2.1	250	0,963	**0,988**	**0,988**
	PixArt-α	250	0,933	0,957	**0,962**
	SiT	250	0,810	0,820	**0,831**
	DiT	250	0,798	0,787	**0,806**
	RDDM	250	**0,759**	0,712	0,745
	CollabDiff	250	**0,666**	0,588	0,641
	DDIM	250	**0,635**	0,526	0,588
GAN	StyleGAN3	250	0,919	0,932	**0,941**
	StyleGAN2	250	0,914	0,922	**0,934**
	StyleGAN-XL	250	0,837	**0,899**	0,888
	VQGAN	250	**0,884**	0,738	0,831
	StarGAN	200	0,772	**0,801**	0,798
	StarGAN v2	199	**0,619**	0,472	0,574
Troca facial	UniFace	250	0,882	**0,931**	0,926
	FaceSwap	250	**0,892**	0,855	0,887
	BlendFace	250	0,817	**0,898**	0,877
	MobileSwap	250	0,803	**0,891**	0,864
	DeepFaceLab	250	0,813	0,844	**0,847**
Edição/ T2I	WhichFaceIsReal	250	0,930	0,944	**0,951**
	MidJourney	248	0,875	**0,934**	0,922
	e4e	250	**0,923**	0,879	0,915
	StyleCLIP	250	0,872	0,893	**0,901**
Misto	Celeb-DF (misto)	500	0,826	**0,876**	0,867
Avatar	*HeyGen*	250	**0,601**	0,530	0,566

E. Celeb-DF v2

O Celeb-DF v2 é o alvo mais difícil. Nenhum modelo individual passa de 0,763 de ROC-AUC por vídeo (Tabela IV), e a

variância entre sementes é alta, como no DINOv3 RGB+SRM ($0{,}755 \pm 0{,}045$). Ao contrário do que ocorre no MFFI, o treinamento robusto RGB reduz a ROC-AUC por vídeo em cinco das seis famílias, possivelmente porque as degradações, desenhadas para o Test-Hard, também suprimem os artefatos sutis de mistura que caracterizam essa base. Os resíduos SRM amenizam essa perda: os melhores ensembles são os sem RGB puro, com DINOv3 e CLIP SRM ($0{,}762$–$0{,}764$), enquanto os híbridos ficam entre $0{,}699$ e $0{,}748$ e os espaciais, entre $0{,}715$ e $0{,}721$.

F. Comparação com a literatura

A Tabela VII compara os resultados deste trabalho com os publicados no MFFI. Entre os métodos treinados somente nessa base, este trabalho chega a $0{,}934$ no Test com um modelo e a $0{,}946$ com ensemble, contra $0{,}877$ do melhor resultado oficial (SRM); no Test-Hard, chega a $0{,}852$ e $0{,}878$, contra $0{,}720$ do RFM. O ganho é maior justamente no Test-Hard, onde o SRM oficial é o mais frágil ($0{,}580$): somado ao RGB com treino robusto, o mesmo tipo de resíduo gera o melhor modelo individual nessa partição. Nenhuma configuração lidera nas duas partições, já que o melhor ensemble no Test perde $0{,}039$ no Test-Hard para o Top-2 espacial.

Detectores treinados no FF++ transferem mal para o MFFI ($0{,}556$–$0{,}779$ no Test), o que mostra que a transferência depende da proximidade entre as bases. Só os modelos multifonte que incluem o próprio MFFI no treino superam esses resultados, como o Venus-DefakerOne2, com mais de 24 milhões de imagens ($0{,}973$ e $0{,}901$), mas eles não são diretamente comparáveis. No Celeb-DF v2, os melhores resultados por vídeo deste trabalho ($0{,}755$–$0{,}764$) ficam acima de todos os detectores oficiais treinados no MFFI ($0{,}560$–$0{,}703$), embora a ROC-AUC absoluta siga modesta.

G. Discussão

Quanto à QP1, o *finetuning* convencional melhora o conjunto limpo, mas não o degradado; só o regime robusto reduz a diferença Test−Test-Hard, para $0{,}06$–$0{,}08$ em todas as famílias, contra $0{,}12$–$0{,}22$ no *finetuning* convencional (Tabela III). Quanto à QP2, os resíduos SRM são um complemento mais útil que a magnitude de Fourier: somados ao RGB, melhoram o DF-40 em cinco famílias e o Celeb-DF no DINOv3, enquanto a magnitude de Fourier tem efeito inconsistente; sozinhos, ambos são insuficientes no domínio de treino.

Quanto à QP3, combinar mais modelos não ajuda sempre: dois ou três modelos de pré-treinamentos distintos concentram o ganho, e o comitê mais eficiente depende do alvo, como discutido na Seção IV-C. Quanto à QP4, a transferência é parcial: os detectores chegam a $0{,}814$ de ROC-AUC no protocolo 1 do DF-40 com um modelo e a $0{,}865$ com ensemble, mas têm pontos cegos em avatares comerciais, parte dos geradores de difusão e StarGAN v2, não passam de $0{,}764$ no Celeb-DF v2, e o limiar calibrado no MFFI não transfere.

Esses resultados sugerem três práticas de avaliação: reportar sempre uma partição degradada e uma base externa, pois o melhor modelo limpo (DINOv3 com *finetuning*, $0{,}936$) fica mais de $0{,}12$ abaixo das versões robustas no Test-Hard; reportar a ROC-AUC por técnica, pois médias escondem técnicas próximas do acaso; e tratar o limiar como dependente do domínio.

H. Limitações

A principal limitação deste estudo está nos próprios modelos, cuja generalização entre bases continua insuficiente: nenhum detector passa de $0{,}764$ de ROC-AUC por vídeo no Celeb-DF v2, todos têm pontos cegos no DF-40 (avatares comerciais, parte dos geradores de difusão e StarGAN v2), e o limiar calibrado no MFFI não transfere para outras bases, o que também penaliza a acurácia (ACC) fora do domínio de treino. Além disso, todos os modelos foram treinados em um único protocolo, com o MFFI como única base de treino, o que impede separar o que é limitação das arquiteturas do que é viés dessa base e dificulta a comparação com a literatura, que costuma treinar no FF++.

V. Conclusões

Este trabalho estendeu o benchmark anterior no MFFI [8] com *finetuning*, treinamento robusto, resíduos SRM, ensembles e avaliação no DF-40 e no Celeb-DF v2. O treinamento robusto fecha a maior parte da lacuna entre os conjuntos limpo e degradado, e os resíduos SRM ajudam como complemento ao RGB, sobretudo fora do domínio de treino. O ensemble Top-2 CLIP+DINOv3 eleva o Test-Hard de $0{,}726$ para $0{,}878$; ensembles híbridos com Fourier levam o Test a $0{,}946$ e o DF-40 a $0{,}865$, ao custo de robustez; e, sem o RGB puro, o par DINOv3+CLIP com SRM alia robustez ($0{,}865$) a um dos melhores resultados no Celeb-DF v2 ($0{,}762$). A generalização entre bases segue como o principal gargalo. Como trabalhos futuros, pretende-se investigar outros protocolos de treino, em especial treinar no FF++ [13] e testar no MFFI, no DF-40 e no Celeb-DF v2, o que permitiria comparar os resultados diretamente com a maior parte da literatura; além disso, pretende-se concluir as rodadas de SRM-only, medir a ROC-AUC sobre todo o split oficial do DF-40 com um conjunto padronizado de reais, calibrar limiares por domínio e avaliar abordagens voltadas a artefatos de mistura, como SBI.

Agradecimentos

Os autores agradecem à Pontifícia Universidade Católica do Paraná (PUCPR) pelo apoio e pela infraestrutura computacional do cluster CISIA, utilizada nos experimentos.

Referências

[1] S. Lyu and The Conversation, "2026 will be the year you get fooled by a deepfake, researcher says. Voice cloning has crossed the "indistinguishable threshold"," Dec 2025. [Online]. Available: https://fortune.com/2025/12/27/2026-deepfakes-outlook-forecast/

[2] D. Milmo, "Company worker in Hong Kong pays out £20m in deepfake video call scam," *The Guardian*, Feb 2024. [Online]. Available: https://www.theguardian.com/world/2024/feb/05/hong-kong-company-deepfake-video-conference-call-scam

[3] The Conversation, "Deepfakes drastically improved in 2025. They're about to get even harder to detect," Jan 2026. [Online]. Available: https://www.fastcompany.com/91469337/deepfakes-surge-2026-detection

Tabela VII

ROC-AUC relatada na literatura e neste trabalho, por base de treino; Celeb-DF v2 só para treino no MFFI (deste trabalho: por vídeo). –: não reportado. ¶Nível não especificado. [a]Só reais do FF++ e pseudofalsas. †Provavelmente o Test. ‡Partição não declarada. §Test e Test-Hard juntos. *Relatado em [26].

Método	Treino	Test	Test-Hard	Celeb-DF v2
Treino no MFFI				
Xception [9]	MFFI	0,852	0,708	0,670¶
RFM [9]	MFFI	0,849	0,720	0,635¶
SRM [9]	MFFI	0,877	0,580	0,560¶
SPSL [9]	MFFI	0,846	0,714	0,703¶
Xception RGB [8]	MFFI	0,884	0,609	–
ResNet-18 RGB [8]	MFFI	0,846	0,635	–
DINOv3 congelado [8]	MFFI	0,809	0,726	–
DINOv3, *finetuning* RGB (este trabalho)	MFFI	0,934	0,737	0,724
DINOv3, RGB+SRM robusto (este trabalho)	MFFI	0,923	0,852	0,755
DINOv3, SRM-only robusto (este trabalho)	MFFI	0,792	0,708	0,763
Top-2 espacial, CLIP+DINOv3 (este trabalho)	MFFI	0,940	**0,878**	0,718
Top-2 sem RGB puro, DINOv3+CLIP SRM (este trabalho)	MFFI	0,933	0,865	0,762
Top-3 sem RGB puro (este trabalho)	MFFI	0,938	0,850	**0,764**
Top-5 híbrido, RGB robusto + Fourier (este trabalho)	MFFI	**0,946**	0,839	0,729
Treino no FF++ (c23)				
Xception [9]	FF++	0,625	0,512	–
RFM [9]	FF++	0,618	0,580	–
SRM [9]	FF++	0,655	0,591	–
SPSL [9]	FF++	0,556	0,543	–
MAP-Mamba [27]	FF++[a]	0,668†	–	–
ReCLIP-SFD [28]	FF++	0,779†	–	–
FMSD [29]	FF++	0,759‡	–	–
Treino multifonte (inclui o MFFI)				
UCF-Net [30]	6 bases	0,909§	0,909§	–
DefakerOne [31]	12,5 M imagens	0,961	0,764*	–
DefakerOne2 [26]	>24 M imagens	0,973	0,901	–

[4] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, "Generative adversarial networks," *Communications of the ACM*, vol. 63, no. 11, pp. 139–144, 2020.

[5] M. Ivanovska and V. Štruc, "On the vulnerability of deepfake detectors to attacks generated by denoising diffusion models," in *IEEE/CVF Winter Conference on Applications of Computer Vision Workshops (WACVW)*, 2024, pp. 1051–1060.

[6] S.-Y. Wang, O. Wang, R. Zhang, A. Owens, and A. A. Efros, "CNN-generated images are surprisingly easy to spot... for now," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020, pp. 8692–8701.

[7] L. Lin, N. Gupta, Y. Zhang, H. Ren, C.-H. Liu, F. Ding, X. Wang, X. Li, L. Verdoliva, and S. Hu, "Detecting multimedia generated by large AI models: A survey," *arXiv preprint arXiv:2402.00045*, 2024.

[8] L. Cunha, L. Sotomaior, L. Gasperin, B. Caldas, E. Pianovski, and R. Laroca, "Benchmarking spatial, spectral, and self-supervised cues for face forgery detection under realistic degradation," Conference on Graphics, Patterns and Images (SIBGRAPI), 2026, arXiv:2609.01511.

[9] C. Miao *et al.*, "MFFI: Multi-dimensional face forgery image dataset for real-world scenarios," in *ACM International Conference on Multimedia (MM)*, 2025, pp. 13 235–13 242.

[10] J. Fridrich and J. Kodovský, "Rich models for steganalysis of digital images," *IEEE Transactions on Information Forensics and Security*, vol. 7, no. 3, pp. 868–882, 2012.

[11] Z. Yan, T. Yao, S. Chen, Y. Zhao, X. Fu, J. Zhu, D. Luo, C. Wang, S. Ding, Y. Wu, and L. Yuan, "DF40: Toward next-generation deepfake detection," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.

[12] Y. Li, P. Sun, H. Qi, and S. Lyu, "Celeb-DF: A large-scale challenging dataset for DeepFake forensics," in *CVPR*, 2020.

[13] A. Rössler, D. Cozzolino, L. Verdoliva, C. Riess, J. Thies, and M. Niessner, "FaceForensics++: Learning to Detect Manipulated Facial Images," in *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019, pp. 1–11.

[14] K. Shiohara and T. Yamasaki, "Detecting deepfakes with self-blended images," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 18 720–18 729.

[15] J. Frank *et al.*, "Leveraging frequency analysis for deep fake image recognition," in *International Conference on Machine Learning (ICML)*, 2020, pp. 3247–3258.

[16] T. Dzanic, K. Shah, and F. Witherden, "Fourier spectrum discrepancies in deep network generated images," *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, pp. 3022–3032, 2020.

[17] Y. Qian, G. Yin, L. Sheng, Z. Chen, and J. Shao, "Thinking in frequency: Face forgery detection by mining frequency-aware clues," in *European Conference on Computer Vision (ECCV)*, 2020, pp. 86–103.

[18] B. Dolhansky, J. Bitton, B. Pflaum, J. Lu, R. Howes, M. Wang, and C. C. Ferrer, "The DeepFake detection challenge (DFDC) dataset," *arXiv preprint arXiv:2006.07397*, 2020.

[19] A. Radford *et al.*, "Learning transferable visual models from natural language supervision," in *International Conference on Machine Learning (ICML)*, 2021, pp. 8748–8763.

[20] O. Siméoni *et al.*, "DINOv3," *Transactions on Machine Learning Research*, 2026, featured Certification. [Online]. Available: https://openreview.net/forum?id=2NlGyqNjns

[21] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, and S. Xie, "A ConvNet for the 2020s," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 11 976–11 986.

[22] F. Chollet, "Xception: Deep learning with depthwise separable convolutions," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 1251–1258.

[23] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.

[24] A. Howard *et al.*, "Searching for MobileNetV3," in *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019, pp. 1314–1324.

[25] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, "An image is worth 16x16 words: Transformers

for image recognition at scale," in *International Conference on Learning Representations (ICLR)*, 2021.
[26] C. Qu, Y. Liang, M. Fang *et al.*, "Venus-DefakerOne2: A vision-forensics foundation model with broader coverage," 2026, technical report, arXiv:2610.37918.
[27] C. Wang, Z. He, X. Hu, W. Guan, W. Wang, and Z. Fu, "MAP-Mamba: Multi-artifacts perception mamba for generalizable face forgery detection," *IEEE Transactions on Information Forensics and Security*, vol. 21, pp. 1184–1197, 2026.
[28] Qiu *et al.*, "ReCLIP-SFD," *IEEE Transactions on Circuits and Systems for Video Technology*, 2026.
[29] X. Zhang, W. Weng, D. Fu, B. Chen, Z. Li, Z. He, and Z. Fu, "Generalizable deepfake detection based on forgery-aware layer masking and multi-artifact subspace decomposition," 2026, arXiv:2601.01041.
[30] X. Zou, Y. Zhou, K. Li, S. Zhang, Y. Chen, C. Lang, and J. Xing, "Harnessing CLIP and DINO: An uncertainty-aware cascaded fusion network for generalizable deepfake image detection," 2026, arXiv:2609.07670.
[31] GuangJian Team, "Venus-DeFakerOne: Unified fake image detection & localization," *arXiv preprint arXiv:2605.14091*, 2026.